// ML-ARENA_CHALLENGE_194 SYS.ORAL_2026-11-04

DS-Harness : Agent Rule-First avec Fallback LLM

Résolution déterministe ciblée & génération Python supervisée sur Qwen2.5-Coder-1.5B

SCORE PRIVATE LEADERBOARD
92.5 % (111/120)

FREEZE DATE
2026-11-03

ÉVALUATION ORAL
2026-11-04

[SYS.01 // CADRE & CONTRAINTES]

Exigences du Challenge ML-Arena

120 TASKS PRIVATE

OBJ.01

Réponse Numérique Unique

Métrique stricte avec tolérance décimale (1.5×10^{-n}).

OBJ.02

Modèle Embarqué Local

Modèle ~1.5B paramètres (Qwen2.5-Coder) et zéro réseau.

OBJ.03

Budget Temps Strict

40s par lot de 8 tâches (soit 5s max par problème).

OBJ.04

Isolation Matérielle

3 vCPUs et 3 GiB de RAM max sans possibilité de dépassement.

[SYS.02 // RATIONALE DE DESIGN]

Pourquoi la Stratégie Rule-First ?

LIMITES

Problèmes du Pur-LLM 1.5B

- Hallucinations fréquentes sur calculs exacts
- Erreurs de syntaxe Python sous pression
- Latence GPU trop élevée par tâche

VERSUS

→

AVANTAGES

Atouts de DS-Harness

- Exactitude mathématique garantie à 100 %
- Exécution instantanée (< 1 ms)
- Budget temps préservé pour les cas complexes

[SYS.03 // FLUX DE TRAITEMENT]

Architecture globale du pipeline



[SYS.04 // MOTEUR DÉTERMINISTE]

Périmètre d’Action des Règles

FAMILLE 01

Fits (20.8 %)

Ajustement automatique de régression linéaire ou logistique sans régularisation avec tolérance aux valeurs NaN.

FAMILLE 02

Tables (41.7 %)

Jointures automatiques, normalisation des clés, filtres de dates et calculs d'agrégats de groupes.

FAMILLE 03

No-files (37.5 %)

Résolution de PPCM, systèmes linéaires, probabilités bayésiennes et formules d'intérêts composés.

[SYS.05 // FALLBACK & AUTOCORRECTION]

Supervision du LLM Qwen2.5-Coder

PROMPTING

Contextualisation Réduite

- Modèle : `Qwen2.5-Coder-1.5B`
- Prompt compact : schéma exact, dictionnaire et exemples guidés

EXECUTION

Boucle Auto-correctrice

- Thread surveillé avec borne temporelle réactive (`max_time`)
- Réparation sur traceback et vote majoritaire pondéré

[SYS.06 // CORRECTIFS INGÉNIERIE]

Robustesse de l'Environnement

PATCH 01

Survie de read_csv

Protection contre la réimportation de Pandas par le code généré.

PATCH 02

SmartFrame Wrapper

Résolution des fautes de frappe et des variations de noms de colonnes.

PATCH 03

Budget Temps Interne

Génération bornée à 29s/40s pour éviter les échecs globaux du lot.

PATCH 04

Harmonisation Clés

Normalisation des préfixes et zéros initiaux avant jointures.

[EVAL.01 // PROTOCOLE]

Dev Set vs Private Leaderboard

DIAGNOSTIC SEULEMENT

Public Dev Set

180 tâches publiques utilisées pour concevoir et valider les règles déterministes.

Score 100 % attendu par construction (biais de conception).

MESURE OFFICIELLE

Private Set (Masqué)

120 tâches masquées évaluant la capacité réelle de généralisation de l'agent.

Seule mesure valide comptant pour le classement.

[EVAL.02 // TRAJECTOIRE]

Progression Private Leaderboard

BEST SUBMISSION

92.5%

111 / 120 TASKS PASSED

VERSION	ÉVOLUTION	SCORE
v1	Agent basique LLM	51.7 %
v2	Règles Fit + Fixes exécution	74.2 %
v3-v4	Règles No-file & Tables	90.8 %
v5 (stage3)	Optimisations déterministes	92.5 %

[EVAL.03 // DÉTAIL PAR FAMILLE]

Scores v5 sur le Private Set

FITS (25 TASKS)

96.0%

24 / 25 RÉUSSIES

NO-FILES (45 TASKS)

95.6%

43 / 45 RÉUSSIES

TABLES (50 TASKS)

88.0%

44 / 50 RÉUSSIES

[SYS.07 // POST-MORTEM]

Analyse des 9 Tâches Manquées

RÉPARTITION DES ÉCHECS

Private Set Loss (9/120)

- **6 Tables :** Types de requêtes complexes non couverts
- **2 No-files :** Formulations d'énoncés hors-templates
- **1 Fit :** Subtilité sur le filtrage des features

BUGS IDENTIFIÉS

Limites Détectées

- `LAST_ERR` non réinitialisé entre candidats LLM
- Exception sur `.round()` appliqué aux floats natifs
- Épuisement du Dev set comme outil de test

// 05_PERSPECTIVES_AND_CLOSE

Recommandations & Étape Suivante

01. HOLDOUT VALIDATION

Évaluer les évolutions sur **`dev_ext.json`** non vu.

02. PATCH STAGE3_PLUS

Déployer le fix mémoire d'erreur et arrondis natifs.

03. TABLES EXPANSION

Enrichir les règles sur la famille Tables (6 échecs).

Merci pour votre attention — Place aux questions (10 min)