// ML-ARENA_CHALLENGE_194 SYS.ORAL_2027-01-06

DS-Harness : Agent Rule-First avec Fallback LLM

Résolution déterministe ciblée, règles croisées & génération Python supervisée sur Qwen2.5-Coder-1.5B

MEILLEURE SOUMISSION · V10	PREMIÈRE SOUMISSION · V1	FREEZE · FIN DE PROJET	ÉVALUATION ORAL
97.5 % (117/120)	51.7 % (62/120)	2027-01-04	2027-01-06 9h–12h

Exigences du Challenge ML-Arena

120 TASKS PRIVATE

OBJ.01

Réponse numérique unique

Métrique stricte avec tolérance décimale (1.5×10^{-n}) pour n décimales demandées.

OBJ.02

Modèle embarqué local

Modèle de ~1.5B paramètres (Qwen2.5-Coder) chargé via `dsh.load_llm`, zéro réseau.

OBJ.03

Budget temps strict

40 s par lot de 8 tâches (5 s par problème), 15 appels. Un dépassement fait échouer le déploiement.

OBJ.04

Isolation matérielle

3 vCPUs et 3 GiB de RAM, sans GPU ni possibilité de dépassement.

NO FILES · 45

Arithmétique, pourcentages, croissance, dates, probabilités, problèmes

« A savings account starts at 5000 euros and earns 4% per year… How much interest has been earned after 4 years? »

TABLES · 50

Statistiques, filtres, classements de groupes, jointures, colonnes dérivées

« Compute the mean amount borrowed for each branch. What is the smallest of these values? » (CSV séparé par « ; », virgule décimale)

FITS · 25

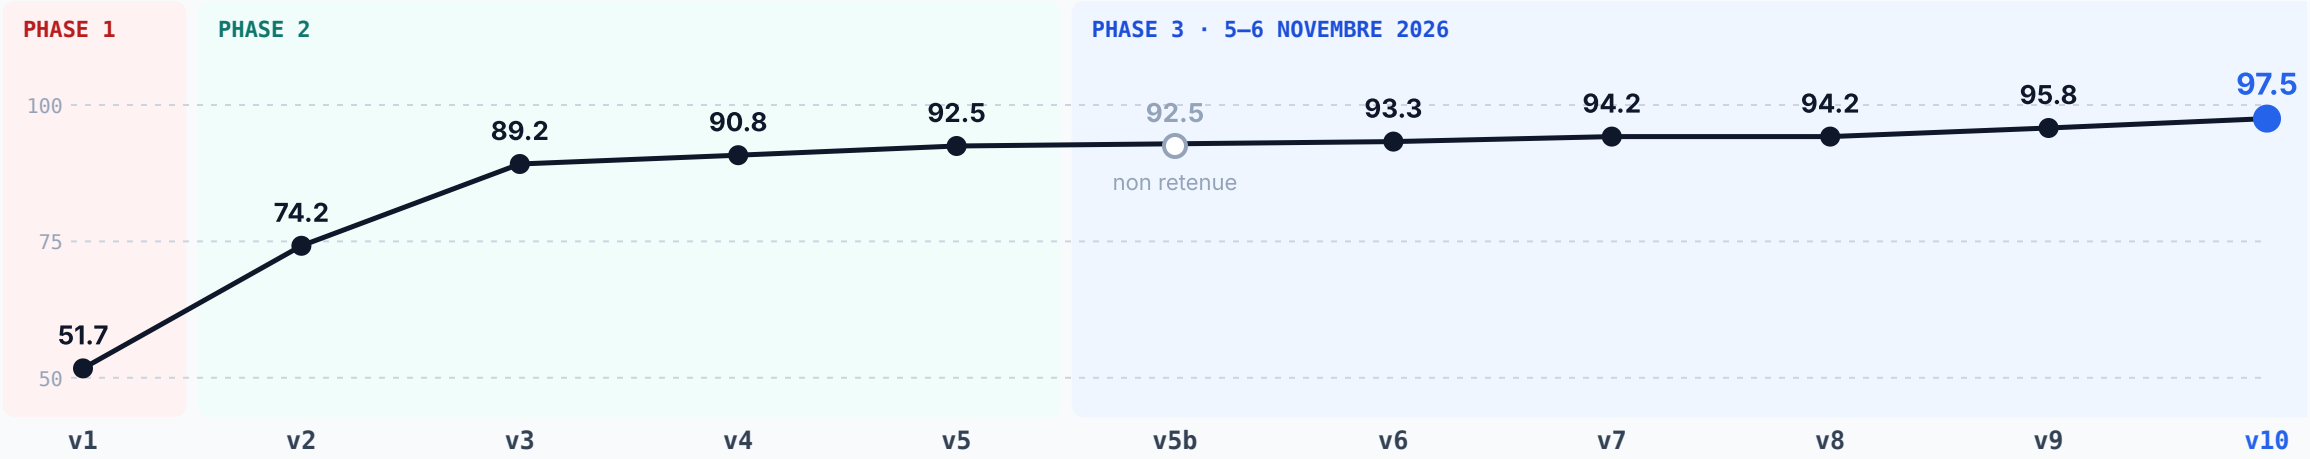
Régression linéaire ou logistique sur `train.csv`

« Fit an OLS regression of the monthly rent on the living area, rooms, floor… What is the intercept? »

[SYS.02 // HISTORIQUE DU PROJET]

10 jalons d'amélioration, en 3 phases

SCORE PRIVÉ (%) DE CHAQUE JALON



PHASE 1 · LE LLM FAIT TOUT

v1	51.7	Le LLM écrit et exécute le code Python de chaque tâche.

PHASE 2 · RÈGLES D'ABORD, LLM EN REPLI

v2	74.2	Règles de fit, correctifs d'exécution du code généré
v3	89.2	Premières règles sans fichier et tables
v4	90.8	Règles sans fichier étendues (+2 tâches)
v5	92.5	Règles de tables affinées (+2) : `stage3.py`

PHASE 3 · ÉLARGIR ET CONTRÔLER LES RÈGLES

v5b	92.5	Réécriture indépendante de toutes les règles ; tables 84 %, non retenue
v6	93.3	Tables de v5, sans fichier et fits de v5b
v7	94.2	+ 21 types de tables absents du dev, veto
v8	94.2	+ gabarits sans fichier, milliers, contrôles de forme
v9	95.8	+ indices du parseur dans le prompt, 8 échantillons
v10	97.5	+ croisement des deux jeux de règles de tables

Chaque jalon est la meilleure variante d'une étape : bien d'autres variantes ont été testées, en local et au leaderboard (exemples slide 14).

Vocabulaire des slides suivantes : « règles historiques » = règles écrites de v2 à v5 (`stage3.py`) ; « règles réécrites » = jeu indépendant écrit en v5b, corrigé de v7 à v10.

[SYS.03 // RATIONALE DE DESIGN]

Pourquoi la Stratégie Rule-First ?

LIMITES

Problèmes du pur-LLM 1.5B

- Hallucinations fréquentes sur les calculs exacts
- Erreurs de syntaxe Python sous pression
- Latence élevée sur CPU, budget de 5 s par tâche
- Notre v1 (LLM seul) : 51.7 % au privé ; référence du challenge : 53.3 % sur le dev

VERSUS →

AVANTAGES

Atouts de DS-Harness

- Réponse exacte dès qu'un gabarit est reconnu
- Exécution en quelques millisecondes
- Budget temps préservé pour les cas ouverts
- **Une règle s'abstient si elle n'est pas sûre**

Leçon de la phase 3 : une règle fausse est pire qu'une abstention. Le LLM rattrape une abstention, jamais une règle qui se trompe.

DÉMARCHE SUIVIE À CHAQUE JALON

1 · DIAGNOSTIQUER
Familles et formulations qui échouent

›

2 · UNE HYPOTHÈSE
Un changement principal à la fois

›

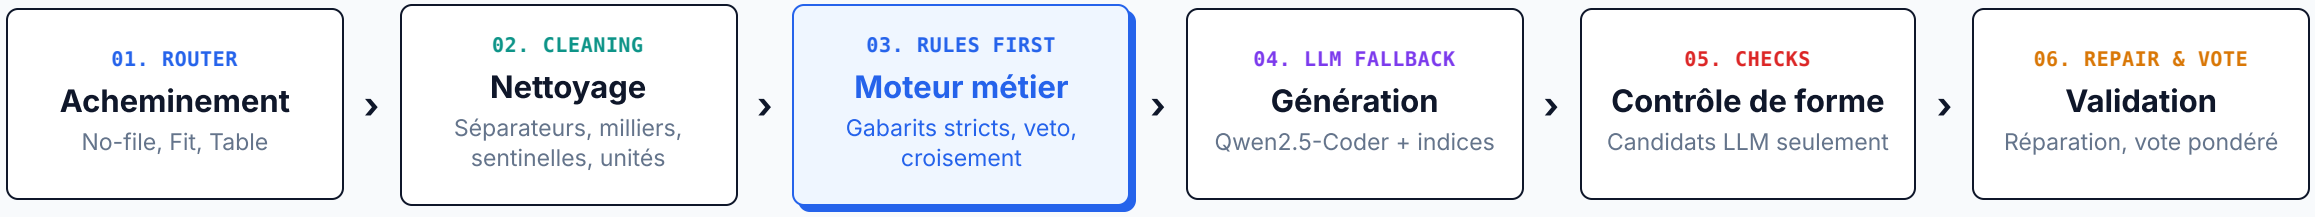
3 · VÉRIFIER HORS LIGNE
Dev, tâches générées, non-régression

›

4 · LE PRIVÉ TRANCHE
La meilleure variante devient le jalon

[SYS.04 // FLUX DE TRAITEMENT]

Architecture globale du pipeline



CHEMIN DES TABLES DANS LA VERSION FINALE (V10)

1 · GABARITS ÉTROITS
21 types absents du dev : IQR, top-k, mode, négations, A ou B…

2 · VETO
Constructions mal lues par les règles historiques → directement au LLM

3 · RÈGLES HISTORIQUES
Code de v2–v5 (`stage3.py`) conservé à l'identique

4 · CROISEMENT
Désaccord avec les règles réécrites → la réponse réécrite gagne

5 · LLM
Prompts de la phase 2 + indices du parseur, 8 échantillons si ≤ 4 tâches

[SYS.05 // MOTEUR DÉTERMINISTE]

Périmètre d'Action des Règles

FAMILLE 01 · 25/25 PRIVÉ (V10)

Fits (20.8 %)

Cible = colonne de `train.csv` absente de `test.csv`. Régression linéaire ou logistique sans régularisation, tolérante aux NaN. Prédiction, R^2, coefficient, odds ratio, moyenne prédite, comptages.

FAMILLE 02 · 48/50 PRIVÉ (V10)

Tables (41.7 %)

Jointures avec clés normalisées, filtres de dates et d'opérateurs, agrégats par groupe. 21 gabarits étroits ajoutés en v7, deux jeux de règles indépendants croisés en v10.

FAMILLE 03 · 44/45 PRIVÉ (V10)

No-files (37.5 %)

PPCM, logarithmes, systèmes linéaires, probabilités, intérêts composés, dates. Environ 130 gabarits ajoutés en phase 3, en trois vagues, chacun strict : il ne répond que si toute la question correspond.

Les règles répondent seules aux 180 tâches du dev public, sans appel au LLM. Ce score est attendu par construction : le privé reste la seule mesure.

[SYS.06 // RÈGLES CROISÉES — AJOUTÉ EN v10]

Deux jeux de règles, une réponse

DIAGNOSTIC

Les règles historiques se trompent parfois sans le savoir

Variantes proches du dev	11 / 500 faux
Types absents du dev	50 / 420 faux

- Mesuré sur des tâches générées, avec vérité connue
- Écart interquartile calculé comme une étendue
- « distinct carriers per depot » compté en lignes
- « not of the Lyon store » lu « of the Lyon store »

RÈGLE DE DÉCISION

Les règles historiques et les règles réécrites répondent et divergent → **la réponse réécrite l'emporte**. Sinon la réponse historique est conservée.

LIMITE VOLONTAIRE

Quand les règles historiques s'abstiennent, la tâche va au LLM avec indices : y appliquer les règles réécrites a coûté 5 tables au privé (86 %).

RÉSULTAT PRIVÉ, V9 → V10

Tables 92 % → 96 %

+2 tâches, score global 95.8 % → 97.5 %

Supervision du LLM Qwen2.5-Coder

PROMPTING

Contexte réduit + indices

- Modèle `Qwen2.5-Coder-1.5B`
- Schéma exact, dictionnaire, un exemple guidé
- **Indices du parseur** : colonnes résolues, population et lignes comptées d'une proportion, filtres

EXÉCUTION

Boucle auto-correctrice

- Thread surveillé, `max_time` sur chaque génération
- Réparation à partir du traceback
- Vote pondéré : glouton 1.5, échantillon 1.0
- **8 échantillons** quand ≤ 4 tâches du lot restent ouvertes

CONTRÔLES

Forme de la réponse

- Fraction, probabilité dans [0, 1]
- Comptage entier, rang ≥ 1, jour 1–7
- Date YYYYMMDD valide, dispersion ≥ 0
- Jamais appliqué aux réponses des règles

EFFET MESURÉ AU PRIVÉ

Indices + 8 échantillons, v8 → v9 : tables 88 % → 92 % (94.2 → 95.8 %)

SÉCURITÉ DES CONTRÔLES

0 vraie réponse rejetée sur 9 811 tâches générées

[SYS.08 // CORRECTIFS INGÉNIERIE]

Robustesse de l'Environnement

PATCH 01 · PHASE 2

Survie de read_csv

Le `read_csv` nettoyé survit à la réimportation de pandas par le code généré.

PATCH 02 · PHASE 2

SmartFrame

Résolution des fautes de frappe et des variations de noms de colonnes.

PATCH 03 · PHASE 2

Budget temps interne

Génération bornée à 29 s sur 40 s pour éviter l'échec global du lot.

PATCH 04 · PHASE 2

Harmonisation des clés

Normalisation des préfixes et zéros initiaux avant les jointures.

PATCH 05 · PHASE 3

Champs contenant « of » et apostrophes

`length of stay` n'est plus coupé en « stay » ; `company's sites` n'ouvre plus de citation.

PATCH 06 · PHASE 3

Opérateurs

`no less than 5` → ≥ 5 ; `(between 0 and 1)` après « fraction » n'est plus un filtre.

PATCH 07 · PHASE 3

Séparateurs de milliers

`24,000` et `1 tonne = 1,000 kg` ne sont plus tronqués à la virgule.

PATCH 08 · PHASE 3

Intérêts seuls

« How much interest has been earned » ne renvoie plus le solde final.

[EVAL.01 // PROTOCOLE]

Dev Set vs Private Leaderboard

DIAGNOSTIC SEULEMENT

Public dev set

180 tâches publiques utilisées pour concevoir et valider les règles déterministes.

100 % attendu par construction (biais de conception).

FILET DE NON-RÉGRESSION

Tâches générées

Générateurs des 7 domaines de tables, 5 domaines de fits, 9 catégories no-file, avec les pièges du dev et une vérité calculée à part.

Utile, mais ne couvre pas toutes les formulations privées.

MESURE OFFICIELLE

Private set (masqué)

120 tâches masquées évaluant la capacité réelle de généralisation de l'agent.

Seule mesure valide pour le classement, et seule mesure du chemin LLM (pas de GPU).

[EVAL.02 // CONTRÔLES HORS LIGNE]

Tester sans le modèle

CONTRÔLE	RÉSULTAT
Dev, règles seules	180/180
Dev, `solve()` complet avec LLM factice	180/180 · ≤ 1.5 s/lot
Tables générées (types dev et nouveaux)	1 548/1 550 · 0 faux
21 nouveaux types de tables, deux tirages	420/420 ×2
No-files générés, trois vagues	100 % · 0 faux
Paraphrases du dev : tables / no-files / fits	765/775 · 542 · 244
Non-régression des no-files, v8 contre v7 (6 505 tâches)	0 régression
Contrôles de forme sur vraies réponses	0 rejet / 9 811

ESTIMATION GOOD-TURING

≈ 1/3

des no-files privées viendraient de sous-gabarits absents du dev. D'où des vagues de gabarits larges plutôt que la chasse à une seule tâche.

PRINCIPE

Vérité calculée sur les données propres, indépendamment de l'agent ; comparaison stricte des réponses et des prompts entre versions.

[EVAL.03 // TRAJECTOIRE]

Score privé de chaque jalon

JALON	CE QUI CHANGE	SANS FICHIER	TABLES	FITS	TÂCHES	SCORE
PHASE 1 · LE LLM FAIT TOUT						
v1	Agent LLM de base	75.6	40.0	32.0	62/120	**51.7**
PHASE 2 · RÈGLES D'ABORD, LLM EN REPLI						
v2	Règles de fit, correctifs d'exécution	77.8	60.0	96.0	89/120	**74.2**
v3	Règles sans fichier et tables	91.1	84.0	96.0	107/120	**89.2**
v4	Règles sans fichier étendues	95.6	84.0	96.0	109/120	**90.8**
v5	Règles de tables affinées (stage3.py)	95.6	88.0	96.0	111/120	**92.5**
PHASE 3 · ÉLARGIR ET CONTRÔLER LES RÈGLES (5–6 NOVEMBRE 2026)						
v5b	Réécriture de toutes les règles (non retenue)	97.8	84.0	100	111/120	**92.5**
v6	Tables de v5, autres familles de v5b	97.8	86.0	100	112/120	**93.3**
v7	+ 21 types de tables, veto	97.8	88.0	100	113/120	**94.2**
v8	+ gabarits sans fichier, milliers, contrôles	97.8	88.0	100	113/120	**94.2**
v9	+ indices du parseur, 8 échantillons	97.8	92.0	100	115/120	**95.8**
v10	**+ croisement des règles de tables**	**97.8**	**96.0**	**100**	**117/120**	**97.5**

Chaque jalon retient la meilleure de plusieurs variantes testées. Scores en % sur les 120 tâches privées (45 sans fichier, 50 tables, 25 fits) ; une tâche = 0.83 point. Référence du challenge : 53.3 % sur le dev (Qwen2.5-Coder seul).

[EVAL.04 // DÉTAIL PAR FAMILLE]

Scores v10 sur le Private Set

FITS (25 TASKS)

100%

25 / 25 RÉUSSIES

v1 32.0 % → v5 96.0 % → **v10 100 %**

NO-FILES (45 TASKS)

97.8%

44 / 45 RÉUSSIES

v1 75.6 % → v5 95.6 % → **v10 97.8 %**

TABLES (50 TASKS)

96.0%

48 / 50 RÉUSSIES

v1 40.0 % → v5 88.0 % → **v10 96.0 %**

SOLUTION RETENUE · AGENT/AGENT_V10.PY

Règles historiques (v2–v5) + 21 gabarits de tables + veto + croisement avec les règles réécrites ; LLM Qwen2.5-Coder avec indices du parseur, 8 échantillons et contrôles de forme. **97.5 % (117/120).**

Depuis v1 : +55 tâches. Sur la phase 3 (v5 → v10) : +1 fit, +1 sans fichier, +4 tables (indices et 8 échantillons +2, croisement +2).

[EVAL.05 // RÉSULTATS NÉGATIFS]

Ce qui n'a pas marché, et ce qu'on en tire

VARIANTES TESTÉES SUR V9 OU V10, NON RETENUES	SCORE
Vote pondéré par l'usage des colonnes du parseur	95.8
12 échantillons, ≤ 6 tâches, second tour	95.8
Indices pour les no-files	95.8
Le LLM arbitre entre les deux jeux de règles	96.7
Règles réécrites aussi là où les règles historiques s'abstiennent	93.3
Règles réécrites partout, avant correction (v5b)	tables 84

LEÇON 1

Même score sur cinq variantes côté LLM → les erreurs restantes étaient **déterministes**.

LEÇON 2

Une règle générique se trompe sur des formulations privées que le générateur ne couvre pas.

LEÇON 3

Le LLM avec indices bat les règles génériques sur les formulations inédites.

LEÇON 4

Bruit de 1 à 2 tâches entre soumissions : seuls v7, v9 et v10 en sortent clairement.

[SYS.09 // POST-MORTEM]

Analyse des 3 Tâches Manquées (v10)

RÉPARTITION DES ÉCHECS

Private set loss (3/120)

- **2 tables** : inchangées par toutes les variantes côté LLM
- **1 sans fichier** : 44/45 sans changement depuis v5b, malgré trois vagues de gabarits
- **0 fit** : famille complète
- Erreurs par tâche non publiées : non inspectables

LIMITES IDENTIFIÉES

Ce qu'il faut dire honnêtement

- `LAST_ERR` non réinitialisé entre candidats LLM (code de la phase 2, conservé)
- Exception sur `.round()` appliqué aux floats natifs
- Jalons retenus parmi de nombreuses variantes testées sur le même privé (biais de sélection)
- Chaque jalon mesuré une seule fois au privé (bruit de 1 à 2 tâches)
- Chemin LLM jamais mesuré hors ligne (pas de GPU)

// 05_PERSPECTIVES_AND_CLOSE

Recommandations & Étape Suivante

01. MESURE LLM HORS LIGNE

Notebook GPU avec les règles coupées (`DSH_RULES_OFF`) pour comparer les réglages du LLM.

02. AUDITER LES RÈGLES HÉRITÉES

Croiser systématiquement deux implémentations : le désaccord révèle les erreurs silencieuses.

03. LE PRIVÉ RESTE L'ARBITRE

Générateurs comme filet de non-régression ; une tâche = 0.83 point, ne pas sur-interpréter.

97.5 %
au private leaderboard (117/120)

+55
tâches réussies de v1 (62) à v10 (117)

0 faux
sur 1 550 tables générées (règles réécrites)

3
tâches privées encore manquées

Merci pour votre attention — Place aux questions (10 min)